

Proyecto final: Análisis de factores que influyen en la victoria en el fútbol europeo



Juan Esteban Daza Forero

Mariana Andrea Hernández Pinto

Docente:
Juan Nicolas Velásquez

Pontificia Universidad Javeriana
Facultad de Ciencias Económicas y Administrativas

29/05/2026

Exploración de datos inicial de la base de datos

La base de datos tiene un tamaño bastante robusto para realizar el análisis estadístico y estructurar los modelos predictivos. Trabajamos con 29.979 partidos y más de 100 variables por partido, lo que enriquece el proyecto. Además, dentro de la información incluye variables como resultados, atributos tácticos por equipos, características físicas de los jugadores y ratings individuales.

Un factor muy importante desde que iniciamos el proyecto fue que muchas variables tienen valores faltantes (NA), específicamente las que se relacionan con posiciones de jugadores y eventos detallados de los partidos. Lo que resulta ser normal en las bases de datos históricas de fútbol ya que no está toda la información disponible en todas las temporadas.

También, la mayoría de las variables tácticas tienen distribuciones centradas alrededor de cero. Lo cual tiene sentido porque son diferencias entre el equipo local y visitante. Por ejemplo:


- $\text{diff_pressure} > 0$ lo que significa que el equipo local tiene mayor presión defensiva.
- $\text{rating_advantage} >$ indica que el equipo local tiene mejor rating promedio.

Lo que nos permite interpretar fácilmente los resultados posteriores.

Distribución de los resultados de los partidos

- 11.917 victorias locales
- 6.596 empates
- 7.466 victorias visitantes

Esta distribución indica que existe una clara ventaja de jugar como local.



Grafica 1. Distribución de resultados

En términos porcentuales:

- 45.9% gana el equipo local
- 25.4% empata
- 28.7% gana el visitante

Este resultado resulta tener sentido con los datos deportivos en los que normalmente existe ventaja de localía por factores como:
Apoyo del publico
Familiaridad con el estadio y campo de juego
Menor desgaste de viaje o traslado
Presión psicológica sobre el rival
Esto nos ayuda a justificar que la variable `home_win_binary` tenga sentido para moldearla de forma estadística.

Variables tácticas de equipos

Construimos diferencias tácticas entre el equipo local y visitante:

- Velocidad de juego (`diff_speed`)
- Presión defensiva (`diff_pressure`)
- Agresividad defensiva (`diff_agression`)
- Creación de juego(`diff_chance_passing`)
- Amplitud defensiva (`diff_width`)

Estas medidas son cercanas a cero porque en el conjunto de datos total no hay un sesgo estructural hacia el local o el visitante; sin embargo, lo que resulta muy importante no es la medida global de los datos sino cómo cambian estas diferencias dependiendo el resultado del partido.


ANOVA de variables tácticas

Presión defensiva

El ANOVA que realizamos para la variable “`diff_pressure`” fue altamente significativo:
$$p < 2e^{-16}$$

Lo que indica que las medidas de presión defensiva son distintas entre las victorias locales, empates y victorias visitantes. El valor F fue muy alto (299.9), lo que muestra alta evidencia estadística.


Es decir cuando el equipo local tiene mayor presión defensiva que el visitante, aumenta la probabilidad de ganar el partido. Ya que es más probable que el quipo recupere el balón más rápido, limita espacios al rival y genera ataques de forma más frecuente durante el tiempo de juego.



Grafica 2. Presión defensiva promedio por resultado

Velocidad de juego

En contraste, `diff_speed` no fue significativo:



Grafica 3. Diferencia de velocidad y resultado

$$p = 0.136$$

Lo que indica que la diferencia de velocidad de juego no cambia de forma clara entre ganar, empatar o perder. Esta variable por sí solo no parece ser determinante ya que un equipo puede que juegue rápido pero de forma desordenada o ineficiente por lo que esto no implica un resultado favorable o desfavorable.

Correlaciones

Variables más relacionadas con la victoria

Las variables con mayor correlación con `home_win_binary` fueron:


- `goal_difference` = 0.79
- `diff_pressure` = 0.14
- `diff_aggression` = 0.14

La correlación entre goles y victoria es muy alta ya que la victoria depende directamente de los goles. Sin embargo, entre las variables tácticas, presión y agresividad si muestran relación positiva.

Variables con poca correlación

Las variables diff_speed y diff_chance_passing no tienen correlación ya que son prácticamente cero.

Lo que significa que estas no tiene relación lineal con la victoria, lo que explica porque en los modelos a continuación resultan no significativas.



Grafica 4. Gráfico de correlaciones variables

Variable	goal_d ifferen ce	home_ win_bin ary	diff_ spe ed	diff_p ressu re	diff_ag gressi on	diff_chan ce_passi ng	home_t eam_g oal	away_t eam_g oal
goal_diff erence	1.00	0.79	0.01	0.18	0.17	0.00	0.77	-0.69
home_wi n_binary	0.79	1.00	0.01	0.14	0.14	0.00	0.64	-0.50
diff_spee d	0.01	0.01	1.00	-0.12	0.11	0.28	0.01	-0.01
diff_pres sure	0.18	0.14	-0.12	1.00	0.50	0.09	0.13	-0.14
diff_aggr ession	0.17	0.14	0.11	0.50	1.00	0.08	0.13	-0.12

Variable	goal_difference	home_win_binary	diff_speed	diff_pressure	diff_aggression	diff_chances_passing	home_team_goals	away_team_goals
diff_chances_passing	0.00	0.00	0.28	0.09	0.08	1.00	-0.01	-0.01
home_team_goals	0.77	0.64	0.01	0.13	0.13	-0.01	1.00	-0.06
away_team_goals	-0.69	-0.50	0.01	-0.14	-0.12	-0.01	-0.06	1.00

Tabla 1. Tabla de correlaciones variables

Modelo 1

Home_win_binary ~ diff_pressure + diff_aggression + diff_speed

Interpretación de coeficientes

diff_pressure $\beta = 0.0037$

Este beta indica que por cada aumento de una unidad en presión defensiva relativa, aumenta ligeramente la probabilidad de victoria local.

diff_aggression $\beta = 0.0039$

Indica que los equipos locales más agresivos defensivamente tienden a ganar más.

diff_speed $\beta = 0.136$

No hay suficiente evidencia estadística para explicar un aumento de victorias por la velocidad.

$R^2 = 0.0248$

Esto quiere decir, que solo explica aproximadamente el 2.5% de la variabilidad.

Este R^2 resulta un poco bajo; sin embargo, el fútbol es complejo de analizar y predecir ya que los resultados dependen de muchos más factores además de los incluidos en las bases de datos analizadas.

La variable dependiente es binaria “home_win_binary = 0 o 1” no es continua. Los modelos lineales funcionan de forma más adecuada cuando la variable objetivo es continua. Ya que cuando se usa una variable binaria el R^2 suele ser bajo, los residuos no tienen un comportamiento perfecto y la capacidad explicativa naturalmente disminuye.

Variable	Estimacion	Error_Estandar	Valor_t	P_valor
(Intercept)	0.4587	0.0031	149.2184	0.0000
diff_pressure	0.0037	0.0003	13.0088	0.0000
diff_aggression	0.0039	0.0003	11.9665	0.0000
diff_speed	0.0004	0.0002	1.4890	0.1365

Tabla 2. Tabla P-value variables significativas

Por lo que en estos casos es mejor utilizar regresión logística, Random Forest y XGBoost.

En investigaciones aplicadas el R^2 bajo resulta ser normal, pero es importante analizar los coeficientes que pueden seguir siendo útiles y significativos. Las relaciones estadísticamente importantes que encontramos fueron la presión y la agresividad defensivas.


Realizamos un Random Forest inicial en el que se obtuvo un error OOB = 41.16% con una precisión aproximada de 58.8% que resulta no ser malo para el futbol.

Las variables más importantes fueron:

- diff_speed
- diff_pressure
- diff_aggression

Aunque la variable “diff_speed” no era significativa en la regresión lineal, si parece ser importante en Random Forest.

Ya que este modelo detecta relaciones no lineales, interacciones complejas y patrones que la regresión no logra capturar.



Grafica 5. Gráfico importancia de variables Random Forest

variable	importancia
diff_aggression	1,067.933
diff_pressure	1,106.097
diff_speed	1,164.665

Tabla 3. Tabla importancia de variables Random Forest

Variables de jugadores

Se incorporaron variables sobre las condiciones físicas de los jugadores como rating promedio, altura y peso. Lo que incorpora dentro del análisis la calidad real de los jugadores de cada liga.


LA variable de rating fue probablemente la más poderosa de todo el proyecto. Con resultados como:

- Cuando gana el local: promedio ventaja rating = +1.93
- Cuando gana el visitante: promedio ventaja rating = -2.55


Lo que indica que los equipos que cuentan con los mejores jugadores tienden a ganar más partidos.

result	avg_rating_advantage	avg_height_advantage	avg_weight_advantage	avg_pressure	avg_speed
Home Win	1.9251	-0.0141	0.1896	1.8939	0.1049
Draw	-0.3748	-0.0510	-0.0558	-0.4233	0.1041
Away Win	-2.5480	-0.0939	-0.4452	-2.6465	-0.2589


Tabla 4. Tabla



Grafica 6. Advantage por resultado



Grafica 7. Ventaja promedio de altura por resultado



Grafica 8. Promedio Rating Advantage por resultado

ANOVA de calidad y físico

El ANOVA del rating fue altamente significativo con $F=2484$. Lo que indica que el rating claramente diferencia partidos ganados y perdidos.

Altura

$$p = 0.084$$

Esta variable resulta no significativa al 5%.

La altura promedio del equipo o parece influir mucho en ganar partidos.

Peso

$$p < 0.001$$

Sí fue significativo Aunque su efecto probablemente sea pequeño.

Modelo 2 Regresión completa

Este modelo resulta ser el más importante de todo el proyecto.

$$R^2 = 0.0248$$

Por lo que este modelo explica aproximadamente el 13.6% de la variabilidad.

Este R^2 mejoro notablemente ya que se agregaron variables demasiado importantes como la calidad de los jugadores, ventajas físicas y diferencias tácticas.

La variable “rating_advantage” capturo gran parte de la capacidad competitiva real de los equipos.

Variable	Estimación	Error Estandar	Valor t	P valor
(Intercept)	0.4559	0.0029	155.4594	0.0000
rating_advantage	0.0388	0.0007	55.6606	0.0000
height_advantage	-0.0028	0.0016	-1.6720	0.0945
weight_advantage	0.0016	0.0007	2.3577	0.0184
diff_pressure	0.0001	0.0003	0.3433	0.7313
diff_aggression	0.0003	0.0003	0.9256	0.3546
diff_speed	0.0002	0.0002	0.6311	0.5280
diff_chance_passing	-0.0001	0.0002	-0.6224	0.5337

Tabla5 . Promedio Rating Advantage por resultado

Interpretación de los coeficientes

Rating advantage


$$\beta = 0.0388$$

Cada punto adicional de ventaja en rating aumenta de forma considerable la probabilidad de victoria local. Es la variable más fuerte del modelo.

Height advantage: no es significative. La Altura no es un determinante en términos generales. Puede resultar importante es situaciones específicas como (balón parado), pero no explica el resultado total.

Variables tácticas

Tras incluir rating, muchas de las variables tácticas dejaron de ser significativas lo que indica que gran parte del efecto táctico estaba correlacionado con la calidad de los equipos, ya que los buenos equipos tienden a tener mejores atributos tácticos.




Grafica 9. Correlación

Variable	home_win_binary	goal_difference	rating_advantage	height_advantage	weight_advantage	diff_pressure	diff_aggression
home_win_binary	1.00	0.79	0.37	0.01	0.04	0.14	0.14
goal_difference	0.79	1.00	0.46	0.01	0.05	0.18	0.18
rating_advantage	0.37	0.46	1.00	0.03	0.08	0.37	0.36
height_advantage	0.01	0.01	0.03	1.00	0.67	-0.04	-0.06
weight_advantage	0.04	0.05	0.08	0.67	1.00	-0.06	-0.07
diff_pressure	0.14	0.18	0.37	-0.04	-0.06	1.00	0.50
diff_aggression	0.14	0.18	0.36	-0.06	-0.07	0.50	1.00
diff_speed	0.01	0.01	0.01	0.03	0.03	-0.13	0.10
diff_chance_passing	0.00	0.00	0.01	0.10	0.05	0.09	0.08

Tabla 6. correlación

Aunque 13.6% parece ser “bajo”, para predicciones deportivas es realmente razonable. Porque en el futbol hay mucho azar, pocos goles, eventos impredecibles y alta variabilidad.



Grafica 9.

variable	importancia
diff_aggression	1,273.354
diff_pressure	1,298.737
diff_chance_passing	1,355.520
diff_speed	1,360.428
height_advantage	1,827.620
weight_advantage	1,928.237
rating_advantage	3,262.903

Tabla 7.

Dashboard interactivo:

Como parte de la fase de despliegue del proyecto, se realizó un dashboard interactivo en Shiny que permite explorar los resultados de forma dinámica. La herramienta incluye filtros por país, liga, equipos y resultado del partido, además de permitir seleccionar las variables utilizadas en el modelo de regresión.

El dashboard muestra indicadores clave del análisis, la ecuación del modelo de regresión con sus estadísticas asociadas, gráficos descriptivos de los resultados

deportivos y visualizaciones de la importancia de variables obtenidas mediante Random Forest. Esto facilita la interpretación de los hallazgos y permite validar de forma visual que la ventaja de rating de los jugadores es el factor con mayor influencia sobre la probabilidad de victoria.

Conclusiones:

El proyecto nos permitió identificar que la calidad de los jugadores es el factor mas importante para explicar la probabilidad de victoria de un equipo local. La variable “rating_advantage” fue la que obtuvo mayor capacidad explicativa dentro de los modelos, lo que evidencia que los equipos que cuentan con mejores jugadores tienden a obtener mejores resultados. Esto significa que, más allá de factores tácticos o físicos, la calidad individual y colectiva tiene un impacto determinante sobre el desempeño deportivo.

Además, el análisis evidencio que variables tácticas como la presión defensiva y agresividad tienen un relación positiva con la victoria. Los equipos locales que presentan mayores niveles de presión y agresividad frente a sus rivales tienden a ganar más partidos. Lo que sugiere que un estilo de juego más intenso y orientado a recurrir de forma rápida el balón puede generar ventajas competitivas importantes durante el partido.

Por otro lado la velocidad de juego no mostró una relación lineal significativa con los resultados. Aunque intuitivamente se pueda pensar que jugar más rápido ayuda a obtener la victoria, los modelos estadísticos indican que esta variable por si sola no explica la victoria.

En cuanto a las características físicas, las variables de altura y peso tuvieron un impacto mucho más limitado en comparación con el rating de los jugadores. La altura incluso dejó de ser significativa en algunos modelos, mientras que el peso mostró efectos pequeños. Esto permite concluir que las características físicas generales del equipo no son suficientes para explicar los resultados de manera sólida dentro del fútbol profesional europeo.

Uno de los hallazgos más importantes del proyecto es que el fútbol presenta un alto nivel de incertidumbre. Aunque el modelo completo logró mejorar el poder explicativo respecto al modelo inicial, los valores de R^2 continuaron siendo relativamente bajos. Sin embargo, esto no significa que el modelo sea incorrecto. El fútbol depende de múltiples factores difíciles de medir, como lesiones, estado emocional, decisiones arbitrales, errores individuales, clima, cansancio y situaciones aleatorias propias del juego. Por esta razón, incluso modelos deportivos avanzados suelen tener capacidades predictivas limitadas.

Finalmente, el proyecto también permitió comparar enfoques estadísticos tradicionales. Mientras la regresión lineal identificó relaciones lineales claras entre algunas variables y la victoria, el modelo Random Forest logró detectar patrones más complejos y no lineales. Esto demuestra que modelos más avanzados pueden capturar comportamientos que los métodos clásicos no alcanzan a identificar completamente.

En términos generales, el análisis realizado fue sólido y completo, ya que incluyó procesos de limpieza y preparación de datos, construcción de variables estratégicas, análisis descriptivo, correlaciones, pruebas ANOVA y regresiones. Además, los resultados obtenidos tienen coherencia tanto desde el punto de vista estadístico como desde la lógica futbolística, lo que fortalece la validez del proyecto y sus conclusiones.